

Learning Analytics: factores predictivos de riesgo del rendimiento estudiantil en entornos virtuales

Fundamentación

Actualmente, las universidades cuentan con una mayor variedad de modelos educativos, como el aprendizaje semipresencial y el aprendizaje electrónico. A pesar de las crecientes oportunidades para estudiantes y docentes, el aprendizaje en línea también plantea desafíos debido a la ausencia de contacto humano directo.

Los entornos virtuales permiten generar grandes cantidades de datos relacionados con los procesos de enseñanza y aprendizaje, lo que ofrece la posibilidad de extraer información valiosa que puede utilizarse para mejorar el rendimiento estudiantil.

Mediante la implementación de metodologías pedagógicas y la ejecución de un modelo de analítica del aprendizaje (*Learning Analytics*) con el fin de monitorear y predecir el aprendizaje de los estudiantes, su desempeño y detectar problemas potenciales de manera temprana para que se puedan proporcionar intervenciones para identificar estudiantes en riesgo de reprobación de un curso o programa de estudio.

Herramientas de código abierto para sistemas de aprendizaje adaptativo, ofertas comerciales y una mayor comprensión de lo que revelan los datos, está conduciendo a cambios fundamentales en los sistemas de enseñanza y aprendizaje. A medida que el contenido se mueve en línea y mediante los dispositivos móviles para interactuar con él, la extracción de datos educativos y el análisis del aprendizaje permitirán aprender a ser siempre evaluado y que la enseñanza esté siempre activa.

I. Resumen Ejecutivo (Executive Summary)

Propósito: Este proyecto responde a una motivación personal de implementar una intervención diagnóstica temprana, para la optimización de los procesos de enseñanza y aprendizaje, en cualquier nivel educativo y de formación tanto presencial como a distancia. A través de la aplicación de las habilidades tecnológicas en modelado, análisis y visualización de datos, adquiridas en mi proceso de reskilling profesional.

Comprender y analizar el desempeño y el comportamiento de aprendizaje de los estudiantes para proporcionar, a través de la agrupación y el análisis estadístico, información significativa sobre cómo el contexto y el comportamiento pueden determinar el proceso de aprendizaje y su correlación con el éxito o el fracaso educativo.

Análisis basados en estas variables de comportamiento de los estudiantes se pueden utilizar en circuitos de retroalimentación, para proporcionar planes de estudio más fluidos y flexibles y para apoyar modificaciones inmediatas del curso (por ejemplo, secuenciación de ejemplos, ejercicios y autoevaluaciones) basado en análisis de datos de aprendizaje en tiempo real.

Objetivo principal: (identificar los principales factores de riesgo y correlaciones con el éxito/abandono). Practicar la implementación e integración de datos, mediante analítica del aprendizaje: aprovechar los sistemas de aprendizaje electrónico reales para recopilar, analizar y visualizar datos de aprendizaje, con el fin de producir conocimientos y estrategias de enseñanza prácticas.

Contexto



La Open University es una universidad pública británica que cuenta con el mayor número de estudiantes de pregrado del Reino Unido. Es la mayor institución académica del Reino Unido (y una de las mayores de Europa), con 2 millones de estudiantes matriculados desde su fundación en 1969. Como su nombre indica, la mayoría de sus estudiantes aprenden a distancia.



Contenido

Conjunto de datos de análisis del aprendizaje de la Open University ([OULAD](#)). Contiene datos sobre cursos, estudiantes y sus interacciones con el Entorno Virtual de Aprendizaje (EVA) para siete cursos seleccionados (denominados módulos). Las presentaciones de los cursos comienzan en febrero y octubre, y están marcadas con las letras «B» y «J», respectivamente. El conjunto de datos consta de tablas conectadas mediante identificadores únicos.

Además, el conjunto de datos incluye información demográfica de los estudiantes, como ubicación, grupo de edad, discapacidad, nivel educativo, género, etc. También se incluyen las calificaciones de las evaluaciones de los estudiantes y sus interacciones con el Entorno Virtual de Aprendizaje (EVA).

II. Metodología y Preparación de Datos

2.1 Fuente de Datos y Modelo E-R

Descripción de los datos

Los registros a utilizar son:

- `assessments.csv`: Este archivo contiene información sobre las evaluaciones en las presentaciones de los módulos. Normalmente, cada presentación incluye varias evaluaciones, seguidas de un examen final.
- `courses.csv`: El archivo contiene la lista de todos los módulos (cursos) disponibles y sus presentaciones.
- `studentAssessment.csv`: Este archivo contiene los resultados de las evaluaciones de los estudiantes. Si el estudiante no entrega la evaluación, no se registra ningún resultado. Las entregas del examen final no se registran si el resultado de las evaluaciones no está almacenado en el sistema.
- `studentInfo.csv`: Este archivo contiene información demográfica sobre los estudiantes junto con sus resultados.
- `studentRegistration.csv`: Este archivo contiene información sobre la fecha y hora de inscripción del estudiante en la presentación del módulo. Para los estudiantes que se dieron de baja, también se registra la fecha de baja.
- `studentVle.csv`: El archivo contiene información sobre las interacciones de cada estudiante con los materiales en el entorno virtual de aprendizaje (VLE).
- `vle.csv`: Este archivo contiene información sobre los materiales disponibles en el entorno virtual de aprendizaje (VLE). Normalmente se trata de páginas HTML, archivos PDF, etc. Los estudiantes tienen acceso a estos materiales en línea y sus interacciones con ellos quedan registradas.


Dataset	Column Name	Description
courses.csv	code_module	Code name of the module (identifier).
	code_presentation	Code name of the presentation (e.g., "2013B" for February, "2013J" for October).
	module_presentation	Length of the module-presentation in days.
assessments.csv	code_module	Code name of the module (identifier).
	code_presentation	Code name of the presentation (e.g., "2013B" for February, "2013J" for October).
	id_assessment	Identification number of the assessment.
	assesment_type	Type of assessment: Tutor Marked Assessment (TMA), Computer Marked Assessment (CMA), or Final Exam.
	date	Submission date of the assessment (number of days since start of module-presentation).
	weight	Weight of the assessment in %. Exams typically have 100%; the sum of other assessments is 100%.
studentAssessment.csv	id_assessment	Identification number of the assessment.
	id_student	Unique identification number for the student.
	date_submitted	Date of student submission (number of days since start of module-presentation).
	is_banked	Flag indicating if the assessment result is transferred from a previous presentation.
	score	Student's score in this assessment (0-100, with scores below 40 considered Fail).
studentInfo.csv	code_module	Code name of the module (identifier).
	code_presentation	Code name of the presentation (e.g., "2013B" for February, "2013J" for October).
	id_student	Unique identification number for the student.
	gender	Gender of the student.
	region	Geographic region where the student lived while taking the module-presentation.
	highest_education	Highest student education level on entry to the module presentation.
	imd_band	Index of Multiple Deprivation band of the student's location during the module-presentation.
	age_band	Band of the student's age.
	num_of_prev_attempts	Number of times the student has attempted this module.
	studied_credits	Total number of credits for the modules the student is currently studying.

studentRegistration.csv	date_registration	Date of student's registration for the module presentation (relative to the start of module).
	date_unregistration	Date of student's unregistration from the module presentation (relative to the start of module).
studentVle.csv	id_site	Identification number for the VLE material.
	date	Date of student's interaction with the material (number of days since start of module).
	sum_click	Number of times a student interacts with the material on that day.
vle.csv	activity_type	Role associated with the module material.
	week_from	Week from which the material is planned to be used.
	week_to	Week until which the material is planned to be used.

Licencia

[Attribution 4.0 International \(CC BY 4.0\)](#)

- El modelo Entidad-Relación (E-R) proporcionado nos permite vincular la información demográfica, de comportamiento (*behavior*), y de rendimiento (*performance*) de manera sólida.



2.2 Cardinalidad entre Entidades

Entidades (Module - Presentation)

- **assessments y courses:**
 - **courses** tiene una relación de uno a muchos (1..*) con **assessments**.
 - **assessments** tiene una relación de uno a uno (1..1) con **courses** (basado en las claves foráneas `code_module` y `code_presentation`).
 - *Resumen: 1 a M (un `code_module` / `code_presentation` tiene muchos `assessments`; un `assessment` pertenece a un solo `code_module` / `code_presentation`).*
- **courses y vle:**
 - **courses** tiene una relación de uno a muchos (1..*) con **vle**.
 - **Tiene** una relación de uno a uno (1. 1) con **courses** (basado en las claves foráneas `code_module` y `code_presentation`).

- *Resumen: 1 a M* (Un [code_module / code_presentation](#) tiene muchos [vle](#) (Entornos Virtuales de Aprendizaje); un [vle](#) pertenece a un solo [code_module / code_presentation](#)).
- **vle** tiene una relación de uno a muchos (1..*) con **studentVle**.
- *Resumen: 1 a M* (Un sitio [vle](#) es accedido muchas veces por estudiantes (registros en [studentVle](#)); un registro de **studentVle** se refiere a un único sitio [vle](#)).
- **assessments** y **vle**: Aquí la tabla **courses** funciona como tabla intermedia entre **assessments** y **vle**, en el diagrama. A través de las claves foráneas [code_module](#) y [code_presentation](#)

Entidades (Student - activities)

- **studentAssessment** y **studentRegistration**:
 - **studentRegistration** se relaciona con **courses** mediante [code_module](#) y [code_presentation](#) y con **studentInfo**, mediante una relación de uno a muchos (1..*) mediante la clave foránea [id_student](#) en el diagrama.
 - **studentAssessment** y **assessments**:
 - **assessments** tiene una relación de uno a muchos (1..*) con **studentAssessment**.
 - **studentAssessment** tiene una relación de uno a uno (1..1) con **assessments** (basado en [id_assessment](#)).
 - *Resumen: 1 a M* (Un [assessment](#) tiene muchos registros en [studentAssessment](#) (ej. muchos estudiantes lo han presentado); un registro de [studentAssessment](#) se refiere a un único [assessment](#)).
 - **studentVle** tiene una relación de uno a muchos (1..*) con **vle** (basado en [id_site](#) y las claves de [code_module](#) y [code_presentation](#)).

Entidades Demográficas y de Registro

- **studentRegistration** y **studentInfo**:
 - **studentInfo** tiene una relación de uno a muchos (1..*) con **studentRegistration**.
 - **studentRegistration** tiene una relación de uno a uno (1..1) con **studentInfo** (basado en [id_student](#) y las claves de [code_module](#) y [code_presentation](#)).
 - *Resumen: 1 a M* (La información de un estudiante en un módulo/presentación ([studentInfo](#)) puede tener múltiples registros de alta/baja ([studentRegistration](#)) – aunque esto parece ser un registro por estudiante/módulo, la notación sugiere 1 a

***M** si un estudiante pudiera registrarse y darse de baja varias veces). **Sin embargo**, dado que [studentInfo](#) ya incluye las claves de **module/presentation**, la relación más lógica es **1 a 1** o **1 a 0..1** para el par único (estudiante, módulo, presentación). Si consideramos solo [id_student](#), sería **1 a M** (Un estudiante tiene muchos registros). **Basado en las claves: 1 a 1** si el registro es por curso y estudiante.*

- **studentInfo y courses:**

- **courses** tiene una relación de uno a muchos (**1..***) con **studentInfo**.
- **studentInfo** tiene una relación de uno a uno (**1..1**) con **courses** (basado en [code_module](#) y [code_presentation](#)).
- Resumen: **1 a M** (Una materia/presentación tiene muchos estudiantes inscritos en [studentInfo](#); un estudiante en [studentInfo](#) pertenece a una sola materia/presentación).

Entidades de Actividades de Estudiantes y Demografía

- **studentInfo y studentAssessment:**

- **studentInfo** tiene una relación de uno a muchos (**1..***) con **studentAssessment**.
- **studentAssessment** tiene una relación de uno a uno (**1..1**) con [studentInfo](#) (basado en [id_student](#) y las claves de [code_module](#) y [code_presentation](#)).
- Resumen: **1 a M** (Un registro de estudiante/módulo en [studentInfo](#) tiene muchos [studentAssessments](#); un [studentAssessment](#) pertenece a un único registro de estudiante/módulo).

- **studentInfo y studentVle:**

- **studentInfo** tiene una relación de uno a muchos (**1..***) con **studentVle**.
- **studentVle** tiene una relación de uno a uno (**1..1**) con **studentInfo** (basado en [id_student](#) y las claves de módulo/presentación).
- Resumen: **1 a M** (Un registro de estudiante/módulo en [studentInfo](#) tiene muchos accesos en [studentVle](#); un registro de [studentVle](#) pertenece a un único registro de estudiante/módulo).

- **studentRegistration y studentVle:**

- **studentRegistration** y **studentVle** se relacionan mediante la tabla intermedia **studentInfo** a través de la clave [id_student](#) (y probablemente las claves de [code_module](#) y [code_presentation](#)), donde el registro es el punto de partida para las actividades.

- **studentRegistration y studentAssessment:**

- **studentRegistration** y **studentAssessment** se relacionan mediante la tabla intermedia **studentInfo** a través de la clave [id_student](#) (y probablemente las claves de [code_module](#) y [code_presentation](#)), donde el registro es el punto de partida para las evaluaciones.

2.3 Combinaciones de Tablas Necesarias (Joins)

El principal desafío es transformar la información granular (clics diarios, evaluaciones múltiples) en métricas resumidas que se vinculen a un único registro de estudiante/módulo.

El *dataset* maestro (**Master Data Set Final= 'df_base'**) se construirá mediante las siguientes uniones (JOIN) en **Python (Pandas)**:

Paso	Tablas de Origen	Claves de Unión	Propósito
1. Base	studentInfo + courses	code_module, code_presentation	Datos Demográficos y Contexto del Curso.
2. Rendimiento	df_base + studentAssessment + assessments	id_student, code_module, code_presentation, id_assessment	Incorporar los puntajes y tiempos de entrega de las evaluaciones.
3. Comportamiento	df_base + studentVle + vle	id_student, code_module, code_presentation, id_site	Incorporar la actividad de clics por tipo de recurso (activity_type).
4. Registro	df_base + studentRegistration	id_student, code_module, code_presentation	Incorporar las fechas de registro y abandono.

2.4 Normalización y Pre-procesamiento de Datos

Dado que el modelo E-R ya está normalizado, la fase de "normalización" aquí se refiere a la **limpieza y transformación de datos** para el modelado en Python (scikit-learn):

Tarea de Pre-procesamiento	Descripción	Python (Librerías Típicas)
1. Manejo de Nulos	Imputar o eliminar filas con datos faltantes, especialmente en <code>date_unregistration</code> (imputar con 0 o usar una <i>flag</i> binaria si el estudiante completó).	Pandas
2. Codificación Categórica	Transformar variables como <code>gender</code> , <code>region</code> , <code>highest_education</code> a formato numérico (e.g., One-Hot Encoding o Label Encoding), ya que los modelos predictivos requieren entrada numérica.	scikit-learn (<code>OneHotEncoder</code> , <code>LabelEncoder</code>)
3. Escalamiento de Features	Escalar variables continuas (ej. <code>total_clicks</code> , <code>score</code> , <code>studied_credits</code>) para que tengan una media de 0 y desviación estándar de 1 (StandardScaler) o un rango de 0 a 1 (MinMaxScaler). Esto es crucial para modelos basados en distancia (ej. regresión logística, redes neuronales).	scikit-learn (<code>StandardScaler</code>)
4. Ingeniería de la Variable Objetivo	La variable <code>final_result</code> (Pass, Fail, Withdrawn, Distinction) se codificará numéricamente para la clasificación (1 para Éxito, 0 para Riesgo).	Pandas, scikit-learn

Nota sobre Agregación: Las tablas [studentAssessment](#) y [studentVle](#) tienen múltiples filas por estudiante/módulo. Antes de la unión final, es esencial agregar (hacer *Feature Engineering*) estas tablas para crear métricas resumen:

- Agregación de Rendimiento (**performance**) {X}: métricas creadas (`first_eval_score`, `avg_initial_score`).
- Agregación de Comportamiento (**behavior**) {X}: métricas creadas (`total_clicks_acum`, `total_active_days`).
- Agregación de **studentVle**: Agrupar por (`id_student`, `code_module`, `code_presentation`) y calcular `total_clicks_acum` (suma de `sum_click`), `total_active_days` (conteo de `date` únicos).

- Agregación de **studentAssessment**: Agrupar y calcular promedio `_score`, `total_score`, y una flag para la primera vez que un estudiante falló un examen.
- Dataset Final: el dataset maestro (`df_base`) utilizado para las visualizaciones, contiene la información de las evaluaciones, sumado a las agregaciones y métricas creadas y la nueva columna "`risk_class`" será la variable {Y} central para todas las visualizaciones y análisis de correlación en las fases posteriores.

2.5. Ingeniería de Features y Consolidación (Feature Engineering)

La ingeniería de características (*feature engineering*) es el proceso de transformar datos brutos en variables (o "features") que un modelo de machine learning pueda usar para hacer predicciones más precisas. Implica el uso de conocimiento del negocio, técnicas estadísticas y matemáticas para seleccionar, transformar y crear nuevas variables que mejoren el rendimiento del modelo.

En qué consiste:

- Preparación de datos: Transforma datos sin procesar en un formato que las máquinas puedan entender y utilizar eficazmente.
- Creación de variables: Extrae o crea nuevas características de los datos existentes. Por ejemplo, convertir una variable numérica continua (como la edad) en una categórica (niño, adulto, anciano).
- Mejora del rendimiento: El objetivo principal es mejorar la precisión predictiva de los modelos de machine learning, ya que los datos brutos a menudo no contienen toda la información necesaria en un formato fácil de usar.
- Proceso iterativo: Es un proceso que no sigue pasos fijos, sino que requiere experimentación y conocimiento del dominio para encontrar la mejor representación de los datos para un problema específico.

Para cumplir con el objetivo del análisis diagnóstico propuesto en este proyecto, se ha optado por una técnica de codificación de datos categóricos.

Definición {Y} (Variable Objetivo): Explicación de la recodificación de la variable categórica `final_result` a binaria: Éxito (1) vs. Riesgo (0).

Justificación Analítica

Al reducir los cuatro resultados a dos clases binarias, logramos lo siguiente:

Simplificación: Convertimos un problema de clasificación de múltiples clases en un problema de clasificación binaria (Éxito vs. Riesgo), lo cual es más fácil de analizar en un proyecto acotado.

Enfoque de Riesgo: La Clase 0 (Riesgo) (Fail/Withdrawn) representa a los estudiantes que requieren intervención. Un estudiante retirado o uno que falla, ambos representan un resultado negativo para la institución, por lo que se agrupan bajo la misma etiqueta de "Riesgo".

Una vez completado este paso, la nueva columna "[risk_class](#)" será la variable {Y} central para todas las visualizaciones y análisis de correlación en las fases posteriores.

2.6 Agrupamiento de datos (K- means clustering)

Para el propósito de este análisis y poder visualizar patrones de comportamiento (*behavior*) y rendimiento (*performance*) en el proceso de aprendizaje de los estudiantes, se ejecutará un acción de agrupamiento por parámetros (*clusters*) y clasificará su desempeño contenido en el **dataset**, con los valores próximos a la codificación (**1 para Éxito, 0 para Riesgo**) de la variable resultado ([final_result](#)).

El algoritmo a emplear será el **k-means**, ya que es un método de agrupamiento que divide un conjunto de datos en **k** grupos o *clusters*. Los datos se agrupan de tal manera que los puntos en el mismo clúster sean más similares entre sí que los puntos en otros *clusters*.

El [agrupamiento K-means](#) es un algoritmo de aprendizaje automático no supervisado que ayuda a agrupar puntos de datos en clústeres según su similitud inherente. A diferencia del aprendizaje supervisado, donde entrenamos modelos con datos etiquetados, K-means se utiliza cuando tenemos datos no etiquetados y el objetivo es descubrir patrones o estructuras ocultas K-means

¿Cómo funciona K-Means?

- Inicialización: Se define el número de clústeres deseados (*k*) y se asignan centroides (puntos centrales) iniciales de forma aleatoria
- Asignación: Cada punto de datos se asigna al clúster cuyo centroide está más cercano, generalmente utilizando la distancia euclidiana.
- Actualización: Los centroides se recalculan como el promedio de todos los puntos asignados a ese clúster.
- Iteración: Los pasos de asignación y actualización se repiten hasta que los centroides ya no cambian significativamente de posición, lo que indica que el algoritmo ha convergido.

III. Análisis Diagnóstico del Rendimiento y Abandono (*Performance*)

El análisis se centrará en responder dos preguntas clave:

1. **Diagnóstico:** ¿Qué factores (demográficos, de comportamiento, rendimiento) se correlacionan con el éxito/fracaso/abandono?
2. **Predictivo:** ¿Podemos predecir el resultado final del estudiante a partir de sus actividades tempranas?

3.1 Análisis Diagnóstico

Este análisis se logra con las visualizaciones y la estadística descriptiva. Permite entender los patrones que ya han ocurrido.

- **Rendimiento:** Determinar la distribución de los resultados finales y cómo las variables demográficas influyen en estos resultados.

Objetivos:

- Determinar la distribución de los resultados y su relación con el contexto académico.
- ¿Quiénes fracasan o abandonan los estudios y qué comportamientos iniciales los diferencian de quienes tienen éxito?

3.2 Visualizaciones a implementar

- **Objetivo:** Determinar la distribución de los resultados y su relación con el contexto académico.

Distribución General de Resultados

- Gráfico de barras de la distribución original de [final_result](#) (Pass, Fail, Withdrawn, Distinction).
- Cálculo de la Tasa General de Riesgo/Abandono.

Impacto de la Primera Evaluación

- Visualización: **Gráfico de Densidad Superpuesto** de la distribución del *score* de la primera evaluación, separada por Éxito y Riesgo
- Análisis del umbral de rendimiento que marca el punto de inflexión hacia el riesgo.

IV. Análisis Diagnóstico del Comportamiento (Behavior)

4.1 Análisis diagnóstico

Este análisis se logra con las visualizaciones y la estadística descriptiva. Permite entender los patrones que ya han ocurrido.

- **Comportamiento:** Identificar los recursos ([activity_type](#)) más y menos utilizados en el VLE, y si el uso tardío de recursos se asocia con un bajo rendimiento.

Objetivo: Identificar si la intensidad o el patrón de actividad VLE está correlacionado con el resultado final.

4.2. Visualizaciones a implementar

- **Clicks Acumulados como Indicador de Éxito**
 - Visualización: **Box Plot** (Diagrama de Caja) de la distribución de **Total Clicks Acumulados**, comparando Éxito vs. Riesgo.
 - Análisis de la diferencia de medias y medianas de actividad entre los grupos.
- **Eficacia de la Actividad**
 - Visualización: **Gráfico de Dispersión** comparando **Puntaje Promedio Inicial** vs. **Total Clicks Acumulados**, coloreado por {Y} (Éxito/Riesgo).
 - Análisis de los cuadrantes: ¿Existen estudiantes con muchos clics y bajo rendimiento (ineficientes) o pocos clics y alto rendimiento (eficientes)?

V. Análisis del Impacto Demográfico y Contextual (Context)

- **Objetivo:** Entender la influencia de factores externos.

5.1 Visualizaciones a implementar

- **Influencia de la Educación Previa y Privación Socioeconómica**
 - Visualización: **Gráfico de Barras Normalizado** de [highest_education](#) vs. Tasa de Riesgo.
 - Visualización: **Gráfico de Barras Normalizado** de [imd_band](#) vs. Tasa de Riesgo.
 - **Correlaciones Finales**
 - Visualización: **Mapa de Calor (Heatmap)** mostrando las correlaciones entre las variables numéricas esenciales (clics, scores, créditos) y la variable objetivo {Y}.
 - Resumen de las 3 variables con mayor correlación con el éxito.
-

VI. Visualizaciones del análisis diagnóstico: objetivos e interpretación analítica

Visualizaciones por variables categóricas



Análisis Diagnóstico y Visualización

El foco es el impacto de las variables demográficas y de las *features* esenciales creadas.


Tarea	Visualización Clave (Python: Seaborn/Matplotlib)	Pregunta Respondida
Comportamiento por géneros	Gráfico de Barras Normalizado por Género: {Y} vs. <code>gender</code> (M,F)	¿Qué género tiene una tasa de éxito o riesgo mayor?
Comportamiento por edades	Gráfico de Barras Normalizado por grupo Edades: {Y} vs. <code>age_band</code> (M,F)	¿Qué grupo etario tiene una tasa de éxito o riesgo mayor?
Impacto Demográfico	Gráfico de Barras Normalizado por Clase: {Y} vs. <code>highest_education</code> , {Y} vs. <code>imd_band</code> .	¿Qué grupos demográficos tienen la mayor tasa de riesgo?
Comportamiento vs. Resultado	Gráfico de Dispersión o Box Plot: <code>total_clicks_acum</code> vs. {Y} (Éxito vs. Riesgo).	¿Hay una diferencia significativa en la actividad VLE entre los que tienen éxito y los que no?
Rendimiento Temprano	Gráfico de Densidad Superpuesto: Distribución del <code>first_eval_score</code> para la Clase 1 (Éxito) y Clase 0 (Riesgo).	¿Cuál es el umbral de <code>score</code> en la primera evaluación que diferencia claramente el éxito del riesgo?
Exploración de Correlaciones	Mapa de Calor (Heatmap) de Correlación: Variables numéricas clave ({X} esenciales y {Y} codificada).	¿Qué <i>feature</i> tiene la correlación lineal más fuerte con el éxito?

Comportamiento vs. Resultado	Serie de Tiempo de Clicks Acumulados por Resultado: Distribución de <code>course_week</code> vs. <code>total_clicks_acum</code>	¿Cuál es la tendencia entre la actividad y el patrón de separación de actividad de los estudiantes en el VLE?
Resultado vs. Actividad	Gráfico de Barras Normalizado por actividad: {Y} vs. <code>activity_type</code>	¿Qué actividad del VLE influye en la Tasa de éxito/riesgo?

6.1 Tasa de Riesgo por Género

Objetivo

Comparar la distribución de la variable objetivo binaria (`risk_class`) para cada valor de la variable `gender` ('M' y 'F'), revelando si un género tiene una tasa de fracaso/abandono significativamente mayor.



Interpretación Analítica


Este gráfico permitirá ver **a simple vista** si la **barra (Riesgo)** es proporcionalmente más alta para un género que para el otro.

- **Podemos observar que la barra de Riesgo, es más alta tanto para 'F' como para 'M':** Indica que tanto las mujeres como los hombres, contenidos en la muestra analizada, tienen una mayor tasa de fracaso/abandono, aunque los hombres inscritos en una leve mayor proporción.
- **Para la barra de Éxito son casi similares:** Indica que el porcentaje de rendimiento son casi comparables entre géneros.

6.2 Tasa de Riesgo por Franja de Edades

Objetivo

Determinar si ciertas franjas de edad ([age_band](#)) muestran una tasa de riesgo (Risk=0\$) significativamente más alta o más baja que otras, lo que indicaría una relación entre la edad y el éxito académico.




Interpretación Analítica


- **Identificación de Riesgo:** La barra (Riesgo) es notablemente más alta en la franja (0-35 años) que en las otras (35-55 / 55<= años), esto sugiere que los estudiantes de esa franja de edad son inherentemente más vulnerables o tienen menos experiencia con el formato de aprendizaje.
- **Juventud vs. Madurez:** En muchos estudios de educación a distancia, se observa que los estudiantes maduros (a partir de 35 años) suelen tener tasas de finalización más altas debido a una mayor motivación y gestión del tiempo, mientras que los estudiantes más jóvenes pueden tener tasas de abandono más altas. La visualización confirma esta hipótesis.

6.3 Gráfico de barras normalizado por clase del impacto demográfico: Y vs. nivel educativo más alto, Y vs. banda de privación.

Objetivo

Mostrar cómo la tasa de riesgo ($\{Y\}=0$) varía entre los niveles de educación previa ([highest_education](#)) y el índice de privación ([imd_band](#)).





Interpretación Analítica

En la primera gráfica “**Previous Education vs. Risk Rate**”, se puede observar que la tasa de riesgo es proporcional al nivel educativo del estudiante. Por lo que a mayor grado de estudios formales, el indicador de riesgo es menor.

“**No formal quals**” significa que un curso, programa o habilidad se obtuvo a través de la educación no formal, que es el aprendizaje organizado fuera del sistema escolar tradicional.

“**Lower than A level**” se refiere a una titulación de nivel académico inferior, como un nivel AS (Advanced Subsidiary), que suele corresponder al primer año de un curso de nivel A y representa el 40 % de la calificación final de este nivel.

“**A-level or equivalent level**” se refiere a una titulación preuniversitaria que demuestra un alto nivel de rendimiento académico, equivalente al último año de la escuela secundaria.

“**HE qualification**” se refiere al aprendizaje postsecundario más allá de la escuela obligatoria, como la universidad.

“**Post Graduate Qualification**” se refiere a un estudiante o a un programa de estudios que se realiza después de completar una licenciatura.

En la segunda gráfica, “**Privation Index (IMD) vs. Risk Rate**”, también podemos observar una relación casi lineal entre la privación de ingresos y el riesgo de fracaso del estudiante.

“**IMD**” significa Índices de Deprivación Múltiple, una medida del gobierno del Reino Unido que clasifica pequeñas áreas geográficas según su nivel de privación. Utiliza una combinación de diferentes dominios, como ingresos, empleo, educación y delincuencia, para crear una puntuación compuesta y clasificar cada área de mayor a menor desfavorecida.

Porcentaje de privación de ingresos

Si el **IMD** se refiere a un dominio específico, como la privación de ingresos, el porcentaje refleja la proporción de personas de esa zona con privación de ingresos.

Cómo interpretar:


Menor porcentaje/clasificación: Mayor desfavorecimiento: Un porcentaje más alto en un dominio específico, como la privación de ingresos, indica un mayor nivel de privación para ese factor.

Mayor porcentaje/clasificación: Menor desfavorecimiento: Un porcentaje más bajo significa menor desfavorecimiento, mientras que un decil más alto (como 9 o 10) indica que el área es menos desfavorecida.

6.4 Comportamiento vs. Resultado / Gráfico de Dispersión (Box Plot)

Objetivo

Determinar si la actividad del (VLE) entorno virtual de aprendizaje ([total_clicks_acum](#)) presenta una diferencia estadísticamente o visualmente significativa entre los grupos de éxito y riesgo.



Interpretación Analítica

Este boxplot sugiere que el **Total de Clics Acumulados** es una variable muy discriminatoria.

1. Diferencia Central Significativa: Existe una clara y sustancial diferencia en la cantidad de clics acumulados entre los dos grupos.
 - Los usuarios clasificados como Éxito (1.0) tienen una mediana de clics mucho más alta (alrededor de 1400) que los de Riesgo (0.0) (alrededor de 400).
 - El 75% de los usuarios de Riesgo tienen menos clics que el 25% inferior de los usuarios de Éxito, lo que indica que el volumen de clics es un fuerte indicador predictivo del resultado final.
2. Distribución de Clics:
 - La distribución del grupo Éxito es más dispersa (caja más ancha), lo que sugiere que hay una mayor variabilidad en el comportamiento de clics entre los usuarios exitosos.
 - La distribución del grupo Riesgo es altamente concentrada en valores bajos (caja muy estrecha), indicando que la gran mayoría de los usuarios de riesgo simplemente no están generando muchos clics.


3. Outliers (Valores Atípicos):

- La presencia de numerosos outliers en ambos grupos (pero más evidente en Riesgo) indica que hay un pequeño porcentaje de usuarios de Riesgo que tienen un volumen de clics inusualmente alto (incluso superando la mediana del grupo de Éxito). Analíticamente, estos podrían ser:
 - Falsos positivos del modelo de riesgo.
 - Usuarios de riesgo que están interactuando mucho, pero que fallan en otra métrica clave.
 - Datos erróneos.

6.5 Rendimiento inicial (Distribución de la primera puntuación)

Objetivo

Visualizar el umbral de la primera puntuación de evaluación que separa a los estudiantes del éxito del riesgo.



Interpretación Analítica

En el gráfico de distribución de resultados finales en relación con la primera evaluación, podemos observar que se subraya que obtener una **puntuación alta** en la primera evaluación es un factor **altamente asociado con el éxito académico** final.

Distribución de la Clase 1 (Success - Éxito)

La distribución para la **Clase 1 (Éxito)**, representada por el área **verde claro**, muestra que:

- **Puntajes Altos Dominantes:** La mayor parte de la densidad se concentra en la parte derecha del gráfico, indicando que los estudiantes que finalmente logran el éxito tienden a tener **puntajes altos** en la primera evaluación.
- **Moda Principal:** El pico más alto (la **moda**) de esta distribución se encuentra aproximadamente alrededor de los **80 a 90 puntos**. Esto sugiere que la puntuación más común para los estudiantes exitosos cae dentro de este rango.
- **Baja Densidad en Puntajes Bajos:** Hay una densidad muy baja en el rango de puntajes de **0 a 40**, lo que significa que es **muy poco común** que un estudiante con una puntuación inicial muy baja termine teniendo éxito.

Distribución de la Clase 0 (Risk - Riesgo)

La distribución para la **Clase 0 (Riesgo)**, representada por el área **roja/salmón**, muestra dos modas o picos principales:

- **Pico de Puntajes Muy Bajos (Riesgo):** Hay un pico de densidad **muy pronunciado** en el extremo izquierdo, alrededor de los **0 a 10 puntos**. Esto indica que una gran proporción de los estudiantes clasificados como en riesgo obtuvieron puntajes extremadamente bajos en su primera evaluación.
- **Pico de Puntajes Medios-Altos:** Existe una segunda moda, menos pronunciada pero significativa, que se extiende aproximadamente de **60 a 80 puntos**. Esto sugiere que una porción de estudiantes en riesgo **no necesariamente** falló completamente en la primera evaluación, lo que podría indicar otros factores (o evaluaciones posteriores) influyendo en su resultado final.

Conclusiones Clave

1. **Alto Valor Predictivo para Extremos:** Los **puntajes muy bajos** (aprox 0-20) son un **fuerte indicador de riesgo**, ya que la densidad de la Clase 0 es significativamente mayor que la de la Clase 1 en ese rango. A la inversa, los **puntajes muy altos** (aprox 90-100)


son un **fuerte indicador de éxito**, con la densidad de la Clase 1 superando ampliamente a la de la Clase 0.

- 2. **Zona de Solapamiento (Ambigüedad):** Existe un solapamiento considerable en el rango de **60 a 85 puntos**. En esta zona, la probabilidad de éxito (área verde) es mayor que la de riesgo (área roja), aunque la presencia de estudiantes de riesgo en este rango sugiere que la primera evaluación **por sí sola no es completamente discriminatoria** y que otros factores de rendimiento o evaluación deben considerarse para predecir el resultado final con certeza.

6.6 Exploración de correlaciones: Mapa de calor (heatmap)

Objetivo

Cuantificar la relación lineal entre las variables numéricas esenciales y el resultado final {Y}.



Interpretación Analítica


Correlaciones con la Clase de Riesgo (1 = Éxito):

risk_class	1.000000
total_active_days	0.625964
avg_initial_score	0.569221
first_eval_score	0.528452
total_clicks_acum	0.476574
num_of_prev_attempts	-0.105460
studied_credits	-0.138630

6.7 Serie de Tiempo de Clicks Acumulados por Resultado

Objetivo

Generar una curva de tendencia que muestre si la actividad total de los estudiantes en la clase **Riesgo (0)** es consistentemente menor y se estanca antes que la de los estudiantes en la clase **Éxito (1)**. Mostrar el momento exacto en el que el comportamiento de los estudiantes de riesgo empieza a divergir del grupo de éxito.



Interpretación Analítica


El análisis de esta gráfica se centra en la **divergencia de las curvas**:

1. **Patrón de Separación:** podemos observar que el punto (semana 0-4) donde la curva de **Riesgo (rojo)** comienza a separarse drásticamente de la curva de **Éxito (verde)**. Por lo que se constituye en el **punto de intervención temprana** ideal.
2. **Actividad Final:** La diferencia vertical al final de la serie muestra la brecha total de actividad entre los estudiantes de Éxito y Riesgo. Como se observa la brecha es grande, lo cual es un indicador clave que la actividad VLE es un factor muy diferenciador.
3. **Tendencia de Crecimiento:** La curva de éxito mantiene una pendiente constante hasta las semanas finales, mientras que la curva de riesgo suele estancarse, demostrando que estos estudiantes dejan de interactuar con la plataforma mucho antes de retirarse formalmente o fallar.

6.8 Tasa de riesgo por tipo de actividad

Objetivo

Determinar si ciertas actividades ([activity_type](#)) presentan una tasa de riesgo significativamente mayor o menor que otras, lo que indicaría una relación entre la actividad y el éxito académico.



Interpretación Analítica

Para cada Activity Type (e.g., [resource](#), [subpage](#), [url](#), etc.), la suma del porcentaje de "Riesgo" y "Éxito" es aproximadamente 100%.

Observación Clave: En la mayoría de las actividades, el porcentaje de Riesgo (rojo salmón) supera el 50%, y en actividades como [externalquiz](#) y [resource](#) se acerca o supera el 60%.

Análisis de la Distribución de Riesgo Base: El análisis de la base de datos [df_base](#) muestra la siguiente distribución global:

- Riesgo (Clase 0): 52.8% (17,208 estudiantes)
- Éxito (Clase 1): 47.2% (15,385 estudiantes)

Conclusión Clave

El resultado del gráfico es un reflejo de la realidad de tus datos: dado que la tasa de riesgo general en la población de estudio es del 52.8%, es completamente normal y esperado que la mayoría de las barras rojas (Riesgo) en el gráfico de actividades superen la barra verde (Éxito).

Categoría	Condición de la Barra Roja (Riesgo)	Ejemplos en el Gráfico	Conclusión
Riesgo Elevado	Es notablemente más larga que el 52.8% (va más allá de la línea vertical del 50%).	externalquiz, resource, subpage	Estas actividades tienen una tasa de riesgo peor que el promedio. Los estudiantes que interactúan con ellas tienen una mayor probabilidad de estar en la clase de riesgo.
Riesgo Promedio	Está cerca del 52.8%.	oucontent, forumng, page, oucollaborate	Estas actividades presentan una tasa de riesgo similar al promedio general del curso.
Riesgo Bajo (Alto Éxito)	Está ligeramente más corta que el 52.8% (y la barra verde es más larga que el 47.2%).	folder, sharedsubpage, htmlactivity	Estas actividades tienen una tasa de riesgo mejor que el promedio. Los estudiantes que las usan tienen una mayor probabilidad de éxito (o menor probabilidad de riesgo).


VII. Modelo de clasificación: Machine Learning no supervisado

Agrupamiento por K-means

Aplicación de K-means a los datos contenidos en el dataset (Master_Data_Set_Final)

- Antes de aplicar K-Means, preparamos los datos del DataFrame
 1. Seleccionar Variables: Excluir la columna de identificación de estudiante (`id_student`) y la columna de clasificación de riesgo (`risk_class`) de los datos que usarás para el agrupamiento.
 2. Manejar Variables Categóricas: K-Means funciona mejor con datos numéricos. Para un desarrollo efectivo, se ha optado por desestimar las variables categóricas para obtener un diagrama más optimizado por las variables numéricas.
 3. Escalar los Datos: El K-Means es sensible a la escala de las variables. Es crucial estandarizar o normalizar los datos para que todas las variables contribuyan por igual a la distancia euclidiana. (scaler: *Normalizer*)
- Determinación del Número Óptimo de Clusters (K)

El K-Means requiere que se especifique el número de clusters (K). El método del codo (*Elbow Method*) es común para esto.



- Aplicación de K-Means y Asignación de Clusters

Aplicamos el algoritmo con el (K) elegido y añadimos la etiqueta de cluster al Data Frame original. Se han creado 4 clusters, con los siguientes valores por variable numérica:

Perfil de los Clusters (medias de las características escaladas - Z-Scores)

Cluster	num_of_p rev_attem pts	studied_cr edits	module_pre sentation_le ngth	avg_initia l_score	first_eval _score	total_clicks _acum	total dias activos
0	0.056282	77.490389	258.235122	81.608258	81.408734	4068.08549 9	149.082577
1	0.121862	92.896389	255.595114	5.062669	2.689166	138.058131	8.025106
2	0.000000	73.680796	255.751615	72.837684	73.565883	874.951254	50.477436
3	1.368501	98.053078	255.038721	64.162715	64.927561	738.68044	41.346748

Análisis de los Clusters y Gráficos de Radar

El perfil del cluster (los centroides) indica las características distintivas de cada grupo. Utilizamos los gráficos de radar como herramientas para visualizar estos perfiles.

- Análisis de Clase de Riesgo por Cluster

Comparamos la distribución de [risk_class](#) en cada cluster para ver si los grupos son homogéneos en términos de riesgo.

Cluster	Fracaso (0) %	Éxito (0) %
0	12.932492695678919	87.06750730432108
1	90.29548088064891	9.704519119351101
2	46.41509433962264	53.58490566037736
3	72.30802697411355	27.691973025886448





Basado en el análisis previo, asumimos la siguiente distribución de riesgo:

Cluster	Fracaso (0) %	Éxito (1) %	Conclusión
0	Bajo	Alto	Estudiantes de Alto Éxito
1	Alto (aprox 90)	Bajo	Estudiantes de Alto Riesgo/Fracaso
2	Moderado	Moderado	Perfil Intermedio-Alto
3	Moderado	Moderado	Perfil Intermedio-Bajo

Visualización con Gráfico de Radar

El gráfico de radar requiere las medias de las características por cluster. Usamos los centroides escalados ([cluster_profile_scaled](#)) para generar los gráficos de radar, uno por cluster, facilitando la identificación de las variables de alto impacto.


Students profile based on 4 Clusters



Análisis individualizado de Clusters y su interpretación para identificar las variables que mejor predicen el éxito (Cluster 0) y el Fracaso (Cluster 1)

Cluster 0: Estudiantes de Éxito y Alto Rendimiento (Bajo Riesgo)

El Cluster 0 representa a los estudiantes con un alto porcentaje de éxito (*risk_class* = 1). Las variables que se desvían positivamente del centro (0) son los factores clave del éxito. Este cluster representa al estudiante "ideal" o de alto desempeño, y es el grupo con **mayor éxito (73.6% Éxito)**.



Característica	Media (Z-Score)	Desviación de la media (0)	Impacto en el Éxito
Puntaje Inicial (avg_initial_score)	76.49	Muy Alto	Alto rendimiento desde el inicio.

Puntaje 1ª Eval (first_eval_score)	76.09	Muy Alto	Rendimiento sostenido y sólido.
Total Clicks (total_clicks_acum)	2452.66	Extremadamente Alto	Alta actividad en la plataforma.
Días Activos (total_active_days)	102.02	Extremadamente Alto	Alto compromiso y persistencia.


Conclusiones del Cluster 0:

Este perfil describe al **estudiante ideal** o de **bajo riesgo**:

- **Alta Preparación Inicial:** Vienen con calificaciones más altas (por [highest_education](#) y [avg_initial_score](#)).
- **Alto Rendimiento Temprano:** Su rendimiento en la primera evaluación ([first_eval_score](#)) es excelente, lo que es un predictor muy fuerte del éxito.
- **Consistencia y Compromiso:** Demuestran mayor dedicación, evidenciada por la gran cantidad de créditos estudiados y la alta interacción/actividad en la plataforma ([total_clicks_acum](#), [total_dias_activos](#)).

Cluster 1: Abandono Temprano (Riesgo Extremo)

El Cluster 1 representa a los estudiantes con un **alto porcentaje de riesgo** (**risk_class** approx 90%= fracaso). Las variables que se desvían negativamente del centro (0) son los **factores clave de riesgo y fracaso**. Este es el grupo de **más alto riesgo (95.2% Fracaso)** y se define por la **casi total inactividad**.



Característica	Media (Z-Score)	Desviación de la media (0)	Impacto en el Fracaso
Puntaje Inicial (avg_initial_score)	7.27	Extremadamente Bajo	Deserción sin siquiera intentar la evaluación o notas muy bajas.

Puntaje 1ª Eval (first_eval_score)	7.33	Extremadamente Bajo	Confirma la falta de participación o nulo rendimiento.
Total Clicks (total_clicks_acum)	17.69	Extremadamente Bajo	No interactúan con el material.
Días Activos (total_active_days)	2.11	Extremadamente Bajo	Abandono en los primeros días.


Conclusiones del Cluster 1:

Este perfil describe al **estudiante en alto riesgo** que probablemente se retirará o fracasará:

- **Poco Compromiso y Desconexión:** La baja actividad ([total_clicks_acum](#), [total_dias_activos](#)) y la baja cantidad de créditos ([studied_credits](#)) indican una falta de compromiso con el estudio a distancia.
- **Mal Comienzo:** El bajo rendimiento en la primera evaluación ([first_eval_score](#)) actúa como una **señal de alerta temprana**.

Cluster 2: (Bajo Rendimiento y Baja Actividad (Alto Riesgo))

Este grupo tiene un **alto riesgo de fracaso (81.1% Fracaso)**, pero con un nivel de actividad ligeramente superior al Cluster 1.




Característica	Media (Z-Score)	Desviación de la media (0)	Impacto en el Fracaso
Puntaje Inicial (avg_initial_score)	52.50	Bajo	Insuficiencia académica clara.
Puntaje 1ª Eval (first_eval_score)	52.84	Bajo	Dificultad para aprobar las primeras instancias.
Total Clicks (total_clicks_acum)	181.24	Bajo	Baja interacción, aunque existe un intento.
Días Activos (total_active_days)	15.31	Bajo	Mayor persistencia que el C1, pero abandono temprano o intermitente.

Conclusión para Cluster 2:

Aquí, la **baja nota inicial** es un predictor de riesgo más fuerte que la inactividad total. Estos estudiantes **intentaron** interactuar y realizar evaluaciones, pero su **rendimiento fue muy bajo**, lo que probablemente condujo al abandono.

Cluster 3: Rendimiento Medio-Bajo (Riesgo Moderado/Alto)

Este cluster se encuentra en el punto medio de la tabla y es el más equilibrado en términos de riesgo (**54.7% Fracaso / 45.3% Éxito**).



Característica	Media (Z-Score)	Desviación de la media (0)	Impacto en el Riesgo
Puntaje Inicial (avg_initial_score)	66.01	Cercano a la media	Rendimiento justo, en el límite de la suficiencia.
Puntaje 1ª Eval (first_eval_score)	65.59	Cercano a la media	Confirma el rendimiento justo.
Total Clicks (total_clicks_acum)	520.89	Cercano a la media	Actividad promedio.
Días Activos (total_active_days)	38.92	Cercano a la media	Persistencia moderada.

Conclusión para Cluster 3:

Este grupo está en la **zona de mayor incertidumbre**. Se caracterizan por un **rendimiento y actividad promedio-bajo**. Son los estudiantes que **necesitan la intervención más estratégica** para inclinarlos hacia el 45% de éxito.

Riesgo: Medio. La puntuación inicial cercana a la media general y el historial de intentos fallidos casi nulos, indica que están **luchando desde el principio**.

Acción: Necesitan **intervenciones inmediatas y focalizadas** al inicio del curso, como tutorías personalizadas, refuerzo de habilidades de estudio y **monitoreo estricto** de la fecha límite de la primera evaluación.

VIII. Conclusiones y Recomendaciones Accionables

- **Conclusiones Clave:** a partir de lo indicado en el resumen ejecutivo, podemos confirmar que las variables de contexto, afectan en cierto grado el desempeño de los estudiantes en la modalidad de educación a distancia:
 - En los gráficos de barras por categorías, se observa que el grupo de mayor edad presenta una probabilidad de éxito considerable en comparación con una franja etaria menor. La diferencia más notable es que los estudiantes de mayor edad parecen tener más probabilidades de obtener la máxima calificación.
 - El desempeño académico parece ser similar en función del género. Con una leve diferencia entre hombres y mujeres.
 - El porcentaje de estudiantes que aprueban o obtienen la máxima calificación aumenta linealmente con el nivel educativo. El porcentaje de estudiantes que reprueban o abandonan los estudios también disminuye linealmente con el nivel educativo.
 - En los gráficos de contexto demográfico, se aprecia claramente que los estudiantes de zonas más desfavorecidas reprueban y abandonan los estudios con mayor frecuencia.
 - Identificación de la **"Diada de Riesgo"** (En resumen, los resultados demuestran que el **abandono temprano (Cluster 1)** y el **bajo rendimiento académico (Cluster 2)** son los dos caminos principales hacia el fracaso

Determinación de Variables que Afectan el Desarrollo

Las variables que mayormente afectan el desarrollo del aprendizaje y el riesgo (éxito/fracaso) son aquellas que muestran la mayor diferencia entre los dos clusters extremos:

Variables Clave (Mayor Diferencia 0 vs 1)	Cómo afecta (Lección)
first_eval_score	El rendimiento temprano es crítico. Una buena puntuación inicial es el predictor más fuerte de éxito.
total_clicks_acum / total_dias_activos	La consistencia y la interacción en la plataforma son vitales. La baja actividad es un indicador temprano de riesgo.

studied_credits	Carga de estudio adecuada. Los exitosos toman más créditos, lo que puede reflejar mayor ambición o capacidad de gestión.
num_of_prev_attempts	Historial académico. Un historial de fracasos/reintentos está fuertemente correlacionado con el fracaso futuro.

Factores Clave de Riesgo y Éxito

Factor	Relación con el Éxito	Cluster de Referencia
Actividad Extrema (total_clicks_acum, total_dias_activos)	Una actividad muy baja es el predictor más fuerte de fracaso (C1). Una actividad muy alta es el predictor más fuerte de éxito (C0).	Cluster 1 vs. Cluster 0
Rendimiento Inicial (avg_initial_score, first_eval_score)	En los estudiantes activos (C0, C2, C3), el puntaje es fundamental. Una nota inicial alta (C0) asegura el éxito. Una nota inicial baja (C2) predice el fracaso a pesar de un intento de actividad.	Cluster 0 vs. Cluster 2
Persistencia (total_active_days)	La baja persistencia diferencia el riesgo: El C1 (2 días) tiene riesgo extremo, mientras que el C2 (15 días) y el C3 (39 días) muestran un intento de continuidad que reduce ligeramente el riesgo, pero sigue siendo alto si el rendimiento es bajo.	Cluster 1 vs. Cluster 2

Recomendaciones de Intervención: Proponer acciones concretas y ejecutables para la institución:

- **Acción 1 (Rendimiento):** Estrategias basadas en el umbral del *Score* inicial.
- **Acción 2 (Comportamiento):** Fomentar la actividad VLE en las primeras semanas, estableciendo un objetivo mínimo de clics.
- **Acción 3 (Demografía):** Asignación prioritaria de tutores a grupos de alto riesgo demográfico.

Acciones Sugeridas

Basándose en estos hallazgos, las intervenciones deberían centrarse en:

1. **Monitoreo Temprano:** Identificar estudiantes con [first_eval_score](#) y [total_clicks_acum](#) bajos tan pronto como sea posible.
2. **Apoyo al Inicio:** Brindar tutorías o recursos adicionales a estudiantes con [highest_education](#) bajo y [num_of_prev_attempts](#) alto.