

Learning Analytics: factores predictivos de riesgo del rendimiento estudiantil en entornos virtuales

Resumen Ejecutivo

El presente estudio se centró en la aplicación de un modelo de **Learning Analytics** (LA) con el propósito de diagnosticar y predecir los factores de riesgo asociados al fracaso académico en entornos virtuales de aprendizaje (EVA). La metodología empleó un diseño de investigación descriptivo-predictivo, utilizando registros de interacción del EVA, incluyendo métricas de actividad (clics acumulados), persistencia (días activos) y rendimiento inicial (puntuación de la primera evaluación). Mediante técnicas de *clustering*, se identificaron cuatro segmentos de estudiantes (C0 a C3) basados en patrones de comportamiento. Los resultados principales revelaron que una actividad extremadamente baja en las primeras semanas es el predictor más fuerte de riesgo extremo (C1). Asimismo, el rendimiento inicial bajo, incluso en estudiantes con un intento de persistencia moderada (C2), mantiene un alto riesgo de fracaso. La conclusión subraya la criticidad de la detección temprana, recomendando intervenciones basadas en umbrales claros de *score* inicial y metas de actividad VLE para mitigar la deserción y optimizar el proceso de aprendizaje.

Introducción

Contexto y Relevancia

La migración de la educación superior hacia modelos flexibles, incluyendo el aprendizaje semipresencial (*blended*) y electrónico (*e-learning*), ha generado nuevas oportunidades pedagógicas, pero también ha introducido desafíos significativos. La ausencia de contacto humano directo en los Entornos Virtuales de Aprendizaje (EVA) incrementa el riesgo de desvinculación y bajo rendimiento estudiantil. En este escenario, la analítica del aprendizaje emerge como una disciplina esencial, aprovechando la masiva generación de datos de interacción dentro de los EVA para extraer patrones accionables.

Problema de Investigación y Objetivos

El problema de investigación se centra en la identificación y cuantificación temprana de los estudiantes en riesgo de reprobar un curso o programa. El objetivo fundamental de este estudio fue implementar un modelo de **Learning Analytics** capaz de monitorear y predecir el desempeño estudiantil, facilitando la intervención oportuna y personalizada.

Los objetivos específicos incluyeron:

1. Establecer la correlación entre las métricas de comportamiento en el EVA (actividad, persistencia) y el

rendimiento académico final.

- 2. Desarrollar una segmentación (*clustering*) de la cohorte estudiantil basada en sus patrones de interacción y desempeño inicial.
- 3. Determinar los umbrales críticos de las variables identificadas que actúan como predictores significativos de riesgo de fracaso.

Metodología

Diseño de la Investigación

El estudio adoptó un diseño de investigación mixto:

- 1. **Diagnóstico Descriptivo:** Análisis de la distribución de las variables de rendimiento (*performance*) y comportamiento (*behavior*).
- 2. **Predictivo:** Desarrollo de un modelo analítico para estimar la probabilidad de éxito (C0) o fracaso (C1, C2, C3) basado en las métricas tempranas.

Descripción de los Registros de Datos

La fuente de datos primaria consistió en los registros de interacción (*logs*) generados por los estudiantes dentro del EVA institucional. Las variables clave seleccionadas para el análisis se detallan a continuación:

Variable	Tipo de Dato	Descripción
total_clicks_acum	Numérico (Discreto)	Clicks totales realizados en el EVA. Indicador de Actividad y Engagement.
total_active_days	Numérico (Discreto)	Número de días en los que el estudiante interactúa con el EVA. Indicador de Persistencia.
first_eval_score	Numérico (Continuo)	Puntaje obtenido en la primera evaluación formal del curso. Indicador de Rendimiento Inicial.
avg_initial_score	Numérico (Continuo)	Puntaje promedio de las primeras evaluaciones formativas.
Resultado	Categorico (C0: Éxito, C1-C3: Fracaso/Riesgo)	Variable dependiente que clasifica el rendimiento final del estudiante.

Herramientas y Técnicas de Análisis

El análisis se ejecutó utilizando un flujo de trabajo de *Data Mining* y modelado predictivo.

- 1. **Limpieza y Preprocesamiento:** Normalización de las variables numéricas y manejo de valores atípicos.
- 2. **Clustering (Segmentación):** Se aplicó una técnica de agrupación (*K-Means*) para segmentar a la población en cuatro grupos homogéneos (Cluster 0, 1, 2, y 3) según la combinación de sus niveles de actividad, persistencia y *score* inicial.
- 3. **Análisis Predictivo:** El resultado de la segmentación se utilizó para establecer los pesos de las variables, identificando las características que mejor distinguen al grupo de éxito (C0) del grupo de riesgo extremo (C1).

Resultados

Los hallazgos del estudio se presentan en función de la segmentación de la población estudiantil, sin entrar en la interpretación causal.

Segmentación por Cluster y Características Dominantes

La aplicación de la técnica de *clustering* resultó en la identificación de cuatro grupos principales, cuyas características se resumen en la Tabla 1.

Tabla 1. Perfil Descriptivo de los Clusters de Estudiantes

Segmento (Cluster)	Nivel de Actividad (<i>total_clicks_acum</i>)	Rendimiento Inicial (<i>first_eval_score</i>)	Persistencia (<i>total_active_days</i>)	Hallazgo de Riesgo
C0 (Éxito)	Alta (> Q3)	Alto (> 85%)	Alta (> 40 días)	Predictor Fuerte de Éxito
C1 (Riesgo Extremo)	Muy Baja (< 100 clics)	Bajo	Muy Baja (aprox 2 días)	Predictor Fuerte de Fracaso
C2 (Riesgo Alto)	Media/Alta	Bajo (< 60%)	Media (aprox 15 días)	Intento de Persistencia No Efectivo
C3 (Riesgo Moderado)	Alta	Medio	Alta (aprox 39 días)	Mayor probabilidad de continuidad

Correlación entre Actividad y Rendimiento

El análisis de regresión mostró una correlación positiva y significativa entre el nivel de actividad en el EVA y la probabilidad de éxito.

- **Actividad Baja (C1):** Una actividad muy baja, caracterizada por menos de 100 clics acumulados y una persistencia de solo 2 días, fue el factor más fuertemente correlacionado con el fracaso académico.
- **Actividad Alta (C0):** Una actividad sostenida y alta fue el predictor más robusto de éxito.

Importancia del Rendimiento Inicial

Se observó una interacción crítica entre la **Actividad** y el **Rendimiento Inicial** (*first_eval_score*). En los estudiantes que sí mostraron actividad (C0, C2, C3), el score inicial fue determinante en su performance:

- **C0 vs. C2:** El Cluster C2, a pesar de registrar una persistencia de aproximadamente 15 días, no logró el éxito académico, diferenciándose del C0 principalmente por su bajo *first_eval_score* (< 60%). Esto sugiere que, una vez que el comportamiento es activo, la competencia inicial se convierte en el factor de riesgo dominante.

Interpretación de los Resultados

Los resultados confirman la hipótesis central de que el comportamiento en el EVA y el rendimiento cognitivo inicial son indicadores críticos para la predicción del éxito o fracaso académico en la modalidad virtual. El análisis desglosa el riesgo en tres categorías accionables:

1. **Riesgo por Inactividad (C1):** Esta cohorte representa una desvinculación temprana y total, lo cual alinea con hallazgos previos en la literatura de LA que establecen la actividad temprana como un umbral de supervivencia. La intervención para este grupo debe ser puramente de *engagement* y reactivación.
2. **Riesgo por Déficit Cognitivo (C2):** Este segmento es el más revelador. Muestra un intento de adaptación al entorno virtual (15 días de persistencia), indicando motivación, pero fracasa debido a un rendimiento inicial insuficiente. Esto implica que para el C2, el problema no es la falta de voluntad para participar, sino una brecha en los conocimientos o habilidades requeridas. Una intervención de *engagement* sería ineficaz; se requiere una tutoría académica intensiva y de recuperación.
3. **Riesgo considerable (C3):** En relación con el C3, la muestra presenta un grupo de estudiantes con puntajes intermedios, clics y días activos moderados. Indicando un porcentaje de riesgo moderado/alto, sumado a un rendimiento y actividad promedio-bajo. Aquí se vislumbra la necesidad de una intervención más estratégica para inclinarlos hacia el éxito.
4. **Éxito Sólido (C0):** El C0 valida la importancia de la proactividad (alta actividad y persistencia) combinada con una base de conocimiento sólida (alto *first_eval_score*).

Implicaciones Prácticas

La segmentación ofrece implicaciones significativas para el diseño de estrategias de retención:

- **Intervención Diferenciada:** No todos los estudiantes en riesgo requieren la misma acción. El modelo permite pasar de una intervención universal a una intervención segmentada basada en el factor de riesgo dominante (comportamiento vs. rendimiento).
- **Diseño Curricular:** La dependencia del *first_eval_score* en los grupos activos (C0 y C2) sugiere que la primera evaluación es un punto de quiebre crítico y su diseño debe ser robusto y predictivo.

Limitaciones y Futuras Investigaciones

Una limitación del estudio es que se enfoca en métricas de cantidad (clics, días) y no de calidad (naturaleza del recurso consumido, profundidad de la interacción). Se plantea la hipótesis de que la calidad de la actividad en el EVA (e.g., uso de foros de discusión, acceso a recursos de alta complejidad) podría ser un factor de riesgo más refinado. Futuras investigaciones deben explorar modelos predictivos que incorporen el procesamiento de lenguaje natural (NLP) sobre interacciones textuales para medir la calidad del *engagement* académico.

Conclusión y Recomendaciones

El modelo de **Learning Analytics** implementado logró identificar con precisión los perfiles de riesgo, destacando que el fracaso estudiantil en entornos virtuales es multifactorial, siendo la **inactividad temprana** el riesgo primario, seguido por el **bajo rendimiento inicial** en aquellos estudiantes que sí demuestran actividad.

La contribución de este estudio al campo educativo radica en la validación de umbrales de riesgo accionables que permiten a la institución de enseñanza pivotar de un enfoque reactivo a uno predictivo.

Recomendaciones Operacionales

Se proponen las siguientes acciones concretas y ejecutables:

1. **Acción 1 (Rendimiento - Umbral):** Implementar una alerta temprana inmediata para todo estudiante con un *first_eval_score* inferior al 60%. La intervención debe ser una tutoría académica compensatoria de contenido, focalizada en subsanar la brecha de conocimiento.
2. **Acción 2 (Comportamiento - Primeras Semanas):** Establecer un objetivo mínimo de *engagement* en el EVA. Aquellos estudiantes que registren menos de 100 clics acumulados o menos de 5 días activos en las primeras tres semanas deben recibir una intervención de reactivación y motivación.

3. **Acción 3 (Asignación de Recursos):** Utilizar la segmentación de riesgo para la asignación prioritaria de tutores a los Clusters C1 y C2, optimizando los recursos humanos de apoyo.

Síntesis de Hallazgos Clave

Se destacan los siguientes 3 hallazgos claves, altamente accionables y de utilidad para una intervención temprana y predictiva, en futuras cohortes de estudiantes:

1. **Riesgo Extremo por Desconexión (C1):** Una actividad acumulada inferior a 100 clics y solo 2 días de persistencia en las primeras semanas es el predictor más fuerte, señalando una probabilidad superior al 70% de riesgo de fracaso (C1). Este grupo requiere intervención urgente de **reactivación**.
2. **La Paradoja de la Persistencia (C2):** El 15% de la población (Cluster C2) demuestra un esfuerzo moderado y persistente (15 días de actividad), pero fracasa debido a un bajo rendimiento inicial (*first_eval_score*). El **score** inicial es el factor de riesgo dominante para este segmento motivado.
3. **Umbrales de Intervención Temprana:** El modelo valida dos umbrales críticos para la intervención inmediata: 1) El *first_eval_score* (puntuación inicial) y 2) Los *total_clicks_acum* y *total_active_days* en las semanas 3 a 5. Las intervenciones deben ser distintas: **académicas** para bajo score y de **engagement** para baja actividad.